

Alzheimer's Intelligent Detection Software(AIDS)

[Lars-Christian Selland, Morten Kvamme, Edvard Steenslid], [27.10.25]



1: BESKRIV PROBLEMET

Har du noen gang stått der, glemt hva du skulle si, hva du tenkte på, hvorfor du er der eller hva pinkoden på simkortet ditt som du ikke har skrevet inn på telefonen på åtte uker fordi telefonen ikke har hatt behov for å bli skrudd av er? Da er det en god sannsynlighet for at du har Alzheimers... eller bare ADHD, men det å finne ut hvilken det er kan være vanskelig, spesielt siden du kommer til å glemme at du hadde denne tanken også om rimelig kort tid, om du ikke har gjort det allerede.

Sistnevnte kan vi ikke gjøre så mye med, men tidlig diagnostisering kan gi deg et tidlig innblikk på om hjernen din sakte råtner av seg selv eller om det er pga. TikTok, slik at du kan gjøre prosessen så langsom som mulig for å gi deg noen ekstra år på jorden der du fremdeles vet forskjellen på venstre og høyre bukseben.

Derfor tok vi for oss problemstillingen om hvordan vi kan bruke maskinlæring for å gjøre antagelser om risiko for Alzheimer slik at mennesker som deg kan finne ut om det kan være lurt å ta en tur til legen for en kjapp test.

Hemmeligheten bak denne tjenestens suksess er at også legene kommer til å ta det i bruk fordi, la oss være ærlige, alle vil være lei av kritisk tenkning etter nærmere 8 år med slitsomme studier. Og alle vet hvor kjedelig manuell sjekking av pasientene vil være. Det er her vår ML tjeneste kommer hardt inn fordi det lar legene slutte å tenke selv og lar dem legge alt ansvaret over på en datamodell som tar alle beslutningene for dem etter de har lagt inn de korrekte parametrene. Dette vil føre til at flere pasienter kan bli sendt gjennom systemet forttere og vil effektivisere sektoren.

Men ja, det finnes nok flere løsninger som dette ute allerede, spesielt i forskningsmiljøer rettet mot Alzheimers, men det positive er som sagt at en modell som dette gjør at leger eller andre må bruke mindre tid på å gjøre disse beregningene manuelt og det vil være tidsbesparende. Den setter ikke diagnosen, men vil gi en god pekepinn på om pasienten kan ha det, og å filtrere ut nok pasienter og ha såpass høy presisjon at den tar mest mulig rett er viktig.

Løsningen skal tas i bruk ved hjelp av at den deployeres på en webserver og vi tenker to modeller, en for pasientene selv som har litt mindre parametre og dermed er mindre treffsikker, og en for helsepersonell med alle parametrene for datasettet og dermed er mye mer treffsikker. Inspirasjonen for dette var sider som legemiddelhåndboka. Det skal sies at vi ikke ser for oss å kunne tjene penger på dette, men donasjoner for å kunne holde tjenesten oppe er en mulighet.

For å forsikre oss at modellen faktisk er brukende så vil vi ha den så nøyaktig som mulig for å unngå for mange false positives som blir sendt til spesialist uten grunn, eller false negatives som blir sendt hjem uten korrekt diagnostisering. Derfor bør vi måle accuracy med en confusion matrix og gå for minimum 0.7 baseline accuracy for privatpersonmodellen, for

hvis det er godt nok for Old School RuneScape, så er det godt nok for vår modell, med mål om 0.75 eller høyere i accuracy.

For den profesjonelle modellen har vi høyere krav og går for en baseline på 0.85, med mål om 0.95 eller høyere i accuracy.

Vi håper også på en god F1 score slik at vi vet at precision og recall er on fleek.

Vi ønsker høy precision for å passe på at modellen faktisk gjettet de forskjellige verdiene korrekt, altså færre false positives, men det viktigste vil være recall, da det er kritisk at modellen får klassifisert mest mulig tilfeller korrekt, spesielt i en medisinsk tjeneste som vår.

Høye verdier her vil gjøre det lettere for både leger og pasienter å kunne stole på verktøyet for trygg diagnostisering og vil igjen gjøre at flere pasienter får diagnose raskt og tidlig.

For å gjøre tjenesten mer aktuell for folk å bruke vil vi satse på lav latency slik at folk får resultatene sine veldig kort tid etter de har lagt inn parameterne.

For moro skyld kan vi kalle throughputen for *ADPS, eller Alzheimers diagnoser per sekund*.

Prosjektet er en suksess om vi etter hvert klarer å halvere tiden legene må bruke på konkludere om mulig alzheimers og det i samme grad hjelper oss med å få økt tidlig diagnostisering med minst 60%, og mtp. antatt accuracy for de to forskjellige modellene forventer vi en brukertilfredshet på over 80% på modellen rettet mot privatpersoner og over 90% for den profesjonelle.

2: DATA

Dataset som blir tatt i bruk er “Alzheimer's Disease Dataset” (Rabie, 2024) som inneholder 2159 syntetisk genererte pasientjournaler. Dataene inneholder en blanding av demografisk, livsstil, medisinsk historikk og kliniske målinger. Disse dataene er også allerede nummerert for å enkelt kunne bruke dataen. Dette er tilstrekkelig grei mengde data for starten av prosjektet for å kunne teste ut de forskjellige maskinlæringsmodellene og lage et konseptbevis. For å få tak i mer data blir innhenting av brukerskrevet data og reell klinisk data veldig viktig.

Prosjektet bruker en “supervised-learning” -metode. Med at modellen skal predikere på kolonnen diagnose. Der 0 er “ikke Alzheimers” og 1 er Alzheimers. Siden datasetet er syntetisk generert, kommer dataen med korrekt satt labels av forfatteren og vi trenger da ikke å utføre manuell merking

Innsamling og bruk av medisinsk data medfører strenge krav til personvern. Selv om det initielle datasettet er syntetisk, må en fremtidig tjeneste håndtere reelle pasientdata.

For å håndtere dette på en etisk forsvarlig måte, må all data som samles inn fra brukere anonymiseres slik at enkeltpersoner ikke kan identifiseres. For innsamling av kliniske data (som i den profesjonelle portalen), må det innhentes eksplisitt samtykke fra hver enkelt bruker (pasient) i tråd med GDPR.

Før dataen kan bli gitt til ML-modellene, må de bli renset og skalert. Dette preprosseringssteget er delt i to. Uavhengig av hvilken modell så blir de ikke prediktive verdiene (PasientID, DoctorInCharge) fjernet. Deretter blir preprosseringsløpet splittet. Det blir lagt 2 forskjellige datasett. Et datasett for den brukervennlige modellen og en for den profesjonelle. Det brukervennlige datasettet blir deretter forenklet ved at de kliniske verdier som Cholesterol, MMSE, ADL og Functional Assesment blir fjernet. Dette gjøres siden en alminnelig bruker ikke forventes å vite disse verdiene. Det andre datasetet blir ikke gjort noe videre med siden vi vil beholde så mange verdier som mulig. Dermed så blir begge datasettet skalert med Standard Scaler siden mange ML-modeller, som Logistic Regression, er følsomme for skalaen på input-verdier.

3: MODELLERING

Målet vårt med dette prosjektet er å ha en nettside der personer kan skrive inn og data og vi gir tilbake en prediksjon om de har eller ikke har Alzheimers. Dette tyder på at vi har et binærklassifiseringsproblem.

Siden datasettet er hentet fra Kaggle, startet vi med å undersøke eksisterende løsninger for å finne en baseline og inspirasjon. Vi fant den høyeste rangerte løsningen av Adhem Ratek og lagde en baseline, samtidig som vi tok inspirasjon. Han analyserte en rekke forskjellige modeller (inkludert Decision Tree, Random Forest, XGBoost, CatBoost, SVM, KNN og Logistisk Regresjon). Hans analyse viste at CatBoost og XGBoost var best, med Random Forest og Decision Tree ikke langt bak. Disse modellene ble selvsagt trent da på det fulle datasettet.

Vår løsning krever at vi har en todelt tilnærming, som vil påvirke modellvalget vårt.

Model 1: Brukevenlig modell.


For å kunne gjøre nettsiden brukervennlig måtte vi fjerne flere variabler som vi ikke kan forvente at en bruker kan oppgi selv, som kolesterol, MMSE (Mini-Mental State Examination) og ADL (Activities of Daily Living).

Da vi testet de antatt beste modellene (Catboost, XGBoost, Decision Tree, Random Forest) på det modifiserte datasettet, fikk vi et stort avvik fra den baselinen. Det viste seg at disse modellene som var best egnet på det fulle datasettet ikke var like egnet på vårt mindre datasett.

Dette førte til at vi revurderte de andre modellene som Tarek tok i bruk (Support Vector Machine, K-nearest Neighbours og Logistic Regression). Vi fant da at Logistic Regression var best med en vektet F1-score på 0.74. Vi valgte derfor å gå videre med Logistic Regression. Selv om at CatBoost var marginalt bedre i våre tester (0.63 f1 score på 1, vs 0.62), er Logistic Regression en mye enklere og raskere modell, noe som er en fordel på nettsiden som kommer til å bli mest brukt. Modellen ble da finjustert med RandomizedSearchCb og lagret for bruk på nettsiden

For å forstå hvilke feil den brukervennlige modellen gjør, satte vi opp en Confusion Matrix:

- True Negative : 228
- True Positive : 90
- False Negative : 63
- False Positive : 49



Dette gir en Accuracy på: $(TP + TN) / (P + N) = (90 + 228) / (139 + 291) = 318 / 430 = 74 \%$

For å kunne forstå denne Accuracy-verdien, kan vi bruke en naiv modell som en baseline. Denne vil alltid gjette på "ikke Alzheimers" (majoritetsklassen). Dette gir oss en accuracy på $277 / 430$, som er 64 %. Vi kan bruke denne verdien for å fastslå at vår modell er betydelig bedre enn hensynsløs gjetting.


Model 2: Profesjonell modell

For den delen av nettsiden som er rettet mot helsepersonell, kunne vi bruke hele datasettet (beholde de kliniske verdiene). Her er kravet for nøyaktig mye høyere, om modellens kompleksitet er mindre viktig.

Basert på de innledende analysene (både vår egen og Tareks) var det tydelig at de mer komplekse modellene presterte bedre på det fulle datasettet. CatBoost hadde best ytelse med en F1-score på 0.96. Her testet vi også Logistic Regression og fikk en score på 0.83, signifikant dårligere. Andre modeller presterte også bra, som XGBoost (0.95) og Random Forest (0.93).

Vi valgte CatBoost her siden denne delen av nettsiden for helsepersonell har mindre trafikk og vil tjene mer på høyest mulig nøyaktighet

- True Negative : 271
- True Positive : 140
- False Negative : 13
- False Positive : 6



Dette gir en Accuracy på: $(TP + TN) / (P + N) = (140 + 271) / (146 + 284) = 411 / 430 = 96\%$

4: DEPLOYMENT

Modellen settes i drift ved å deployes på en av våre lokale servere. Fra der kan privatpersoner og leger utnytte tjenesten. Prediksjonene som vi gjør vil gjerne, for den brukervendelige delen, oppfordre brukeren til enten få seg selv testet eller for å minke frykten deres. For helsepersonell siden så er den der for å hjelpe dem å diagnostisere en pasient for mulig Alzheimers.

Vi vil [monitorere](#) at kvaliteten på modellen vår ikke drifter etter hvert slik at modellen holder høy accuracy over tid og derfor holder kvalitet.

Hvis vi oppdager noen discrepancies så vil vi vedlikeholde modellen med å gjentrene den slik at modellen fungerer som den skal og ikke begynner å feildiagnosere mer enn den burde. Det vil også under vanlig bruk bli hentet inn data fra brukerne som kan hjelpe oss med videreutvikling av nyere, mer accurate modeller som vil komme alle til nytte.

5: REFERANSER

Rabie El Kharoua. (2024). 🧠 Alzheimer's Disease Dataset 🧠 [Data set]. Kaggle.
<https://doi.org/10.34740/KAGGLE/DSV/8668279>

Tarek, A. (2024). *Alzheimer's disease prediction*. Kaggle.
<https://www.kaggle.com/code/adhamtarek147/alzheimer-s-disease-prediction>

Géron, Aurélien. (2023) *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow Concepts, Tools, and Techniques to Build Intelligent Systems*. (3rd ed). O'REILLY

Lars-Christian Sellands hjerne (1995)